编译原理与设计实验报告

姓名：卜梦煜　　学号：1120192419　　班级：07111905

1. 实验名称

词法分析实验

2. 实验目的

（1）熟悉 C 语言的词法规则，了解编译器词法分析器的主要功能和实现技术，掌握典型词法分析器构造方法，设计并实现 C 语言词法分析器；

（2）了解 JFlex 工作原理和基本思想，学习使用工具自动生成词法分析器；

（3）掌握编译器从前端到后端各个模块的工作原理，词法分析模块与其他模块之间的交互过程。

3. 实验内容

根据 C 语言的词法规则，设计识别 C 语言所有单词类的词法分析器的确定有限状态自动机，并使用 Java 语言，采用数据中心法设计，使用 JFlex 自动生成实现词法分析器。词法分析器的输入为 C 语言源程序，输出为属性字流。

4. 实验环境

jdk-17.0.2，JFlex-1.8.2

5. 实验过程与步骤

实验方法为使用 Java 语言和 JFlex 自动生成 C 语言词法分析器，实验步骤包括安装 JFlex、编写.l 规则文件、JFlex 编译.l 文件生成 Java 程序、将该程序嵌入 BITMiniCC 框架。

5.1 安装、配置 JFlex

（1）github 下载最新版的 JFlex 压缩包，解压文件夹。

（2）用记事本打开 /bin/jflex.bat 文件，修改 jdk 安装路径和 JFlex 安装路径。

（3）将 JFlex 添加至系统环境变量。

5.2 编写.l 规则文件

查看 JFlex 用户手册，JFlex 的.l 规则文件结构如下：

```
UserCode
%%
Options and declarations
%%
Lexical rules
```

按照图示结构编写各部分代码：

（1）用户代码

该部分包括 java 程序的包声明和导入语句。本实验导入 java.io 库进行文件读写操作。

（2）选项与声明

该部分包括生成词法分析器、词法状态声明、宏定义的代码。

首先编写 JFlex 系统可选项，包括%class 定义词法分析器类名，%type 定义词法分析器返回值的数据类型，%line 开启行计数，%column 开启列计数。

```
5   %class Scanner
6   %type String
7   %column
8   %line
```

然后编写用户代码，包括变量定义、正则表达式 Token 的枚举类定义。这部分代码放在%{和%}之间，会原样拷贝到生成的词法分析器文件中。本文定义的 Token 类型包括关键词、标识符、整型常量、浮点型常量、字符常量、字符串字面量、运算符、界限符、空格、注释，基本覆盖了 C 语言单词类的所有内容。自定义的函数为行列数的 get 方法。

```
10  %{
11
12      public int line = 1;
13
14      public enum TokenType{
15          KEYWORD, IDENTIFIER, INTEGER, FLOAT,
16          CHAR, STRING, OPERATOR, BOUND, BLANK, ANNOTATION;
17      };
18
19      public int getYyline(){
20          return yyline;
21      }
22
23      public int getYycolumn(){
24          return yycolumn;
25      }
26
27  %}
```

最后根据 C 语言单词类的定义，编写正则表达式，各 Token 正则表达式编写如下。

对关键字，按词直接识别 C 语言所有关键字，正则表达式如下：

```
// 关键词
Keyword = (auto|break|case|char|const|continue|default|do|double|else|enum|extern|float|for|goto|if|inline|
           int|long|register|restrict|return|short|signed|sizeof|static|struct|switch|typedef|union|unsigned|
           void|volatile|while)
```

对运算符，识别包括算术运算符、逻辑运算符、关系运算符、位运算符、赋值运算符，其他杂项运算符，直接按照运算符内容编写正则表达式如下：

```
// 运算符
Operator = "."|"->"|"++"|"--"|"&"|"*"|"+"|"-"|"~"|"!"|"/"|"%"|"<<"|">>"|"<"|">"|
           "<="|">="|"=="|"!="|"^"|"|"|"&&"|"||"|"?"|":"|";"|"..."|"="|"*="|"/="|
           "%="|"+="|"-="|"<<="|">>="|"&="|"^="|"|="|"sizeof"
```

对界限符，直接识别 C 语言所有界限符，正则表达式如下：

```
// 界限符
Bound = (\[|\]|\(|\)|\{|\}|,|;|\'|\"|#)
```

对标识符，格式为非数字开头的数字、字母、下划线，正则表达式如下：

```
Character = [a-zA-Z]

// 标识符
Identifier = ({Character}|_)({Character}|_|{Digit})*
```

对整型常量，识别包括十进制、八进制、十六进制整型常量。对十进制数，格式为 [符号]<整数部分>[后缀] ；对八进制数，格式为 [符号]<0><整数部分>[后缀] ；对十六进制数，格式为 [符号]<0{X, x}><整数部分>[后缀] 。正则表达式如下：

```
Digit = [0-9]
NonzeroDigit = [1-9]
OctalDigit = [0-7]
NonzeroOctalDigit = [1-7]
HexadecimalDigit = [0-9a-fA-F]
NonzeroHexadecimalDigit = [1-9a-fA-F]

IntegerSuffix = ([Uu](L|l|LL|ll))|((L|l|LL|ll)[Uu])

UnsignedInteger = {NonzeroDigit}{Digit}*|0
DecimalIntegerConstant = ("+"|"-")?{UnsignedInteger}{IntegerSuffix}?
UnsignedOctalInteger = {NonzeroOctalDigit}{OctalDigit}*|0
OctalIntegerConstant = ("+"|"-")?0{UnsignedOctalInteger}{IntegerSuffix}?
UnsignedHexadecimalInteger = {NonzeroHexadecimalDigit}{HexadecimalDigit}*|0
HexadecimalIntegerConstant = ("+"|"-")?0[Xx]{UnsignedHexadecimalInteger}{IntegerSuffix}?

// 整型常量
IntegerConstant = {DecimalIntegerConstant}|{OctalIntegerConstant}|{HexadecimalIntegerConstant}
```

对浮点型常量，识别十进制、十六进制浮点型常量。对十进制数，格式为 [符号]<整数部分>[.小数部分][{E, e}<十进制整数>][后缀] ； 对十六进制数，格式为 [符号]< 0{X, x}><整数部分>[.小数部分][{P, p}<十进制整数>][后缀] 。正则表达式如下：

```
FloatSuffix = f|l|F|L
DecimalFloatConstant = {DecimalIntegerConstant}([\.]{UnsignedInteger})?((E|e){DecimalIntegerConstant})?{FloatSuffix}?
HexadecimalFloatConstant = {HexadecimalIntegerConstant}([\.]{UnsignedHexadecimalInteger})?((P|p){DecimalIntegerConstant})?{FloatSuffix}?

// 浮点常量
FloatConstant = {DecimalFloatConstant}|{HexadecimalFloatConstant}
```

对字符常量，识别单引号内的前缀加普通 ASCII 码字符常量、转义符常量、八进制字符常量、十六进制字符常量。普通 ASCII 码字符常量为 ASCII 码 0~127 去除'、\、Tab；转义符常量包括\v 等 11 个；八进制字符常量为转义符的八进制表示，格式为 <\>[000-177]；十六

进制字符常量为转义符的十六进制表示，格式为 <\>{X, x}[00-7f]。正则表达式如下：

```
Char = [\x00-\x09\x11-\x26\x28-\x5B\x5D-\x7f]
EscapeChar = \\(a|b|f|n|r|t|v|\'|\"|\?|\\)
OctalEscapeChar = \\{OctalDigit}{1,3}
HexadecimalEscapeChar = \\[Xx]{HexadecimalDigit}{1,2}

// 字符常量
CharConstant = [LUu]?\'({Char}|{EscapeChar}|{OctalEscapeChar}|{HexadecimalEscapeChar})\'
```

对字符串字面量，识别为双引号内的前缀加普通 ASCII 码字符常量、转义符常量、八进制字符常量、十六进制字符常量。正则表达式如下：

```
// 字符串字面量
StringLiteral = ["u8"uUL]?\"({Char}|{EscapeChar}|{OctalEscapeChar}|{HexadecimalEscapeChar})+\"
```

（3）词法规则

该部分包括正则表达式和扫描程序匹配到该正则表达式后执行的操作，主要为 Token 标签的返回，以及换行、空格与 Tab、文件尾的识别，用于后续文件识别标签。该部分代码如下：

```
  \n {++line;}

  {Keyword} {return TokenType.KEYWORD.name();}

  {Identifier} {return TokenType.IDENTIFIER.name();}

  {IntegerConstant} {return TokenType.INTEGER.name();}
  {FloatConstant} {return TokenType.FLOAT.name();}

  {CharConstant} {return TokenType.CHAR.name();}
  {StringLiteral} {return TokenType.STRING.name();}

  {Operator} {return TokenType.OPERATOR.name();}
  {Bound} {return TokenType.BOUND.name();}

  [ \t]+ {return TokenType.BLANK.name();}

  "//"[^\n]*\n {return TokenType.ANNOTATION.name();}   // 识别单行注释
  "/*"([^*]|\*+[^/*])*"*/" {return TokenType.ANNOTATION.name();}   // 识别多行注释
  <<EOF>> {return "EOF";}
```

5.3 JFlex 编译.l 文件生成 Java 程序

用 JFlex 编译.l 规则文件生成 Java 文件，命令为 JFlex myScanner.l，生成 Scanner.java 词法分析器。

5.4 嵌入 BITMiniCC 框架

（1）编写 MyCScanner.java 文件作为词法分析器入口。将上一步生成的 Scanner.java 文件移动到 BITMiniCC 的/src/bit/minisys/minicc/scanner/ 中，编写 MyCScanner.java，将词法分析器嵌入 BITMiniCC 框架。

MyCScanner 包括三部分：重写 run()方法，嵌入 BITMiniCC 框架；Token 识别方法，识别单词，成功识别则调用 Token 生成函数，否则调用错误处理代码；Token 生成方法，生成识别的单词的 Token 标签。

(2)修改 BITMiniCC 配置文件。将除词法分析外的步骤 skip 设为"true", 将 MyCScanner。Java 路径加入词法分析的 path 中。

（3）添加测试的.c 文件路径至 BITMiniCC.java 文件的实参。

（4）运行 BITMiniCC。

6. 运行效果截图

测试文件为提供的 1_scanner_test.c 文件。idea 运行截图如下，可以看到词法分析器能够正常工作:

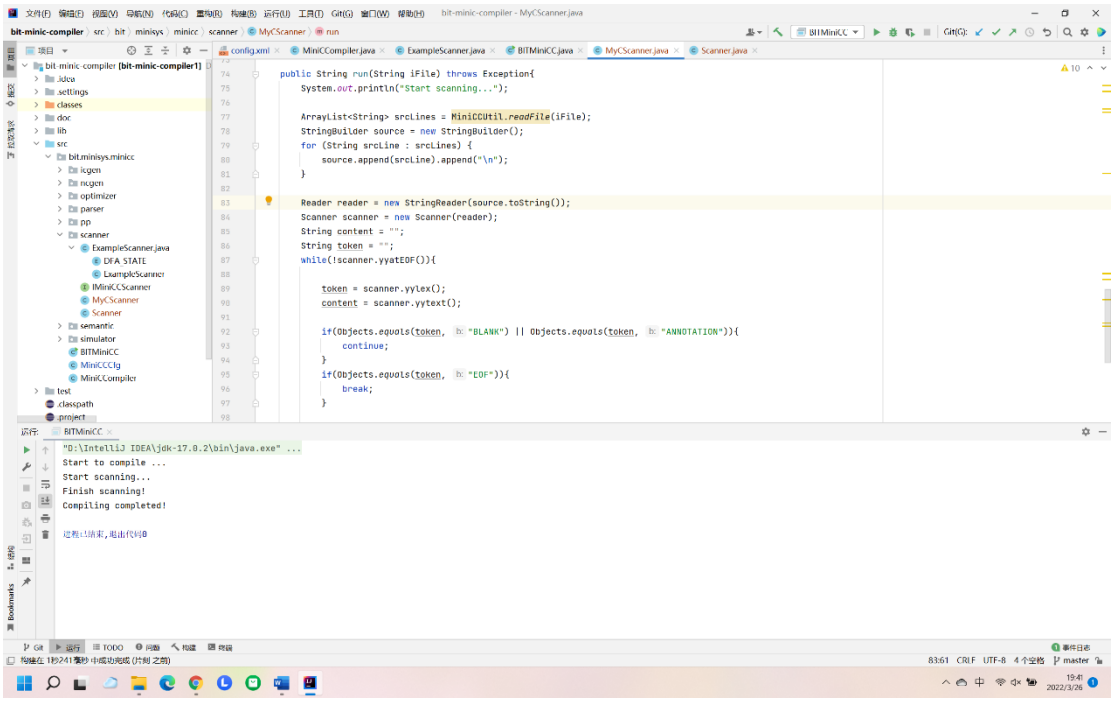

生成的文件包括 1_scanner_test.c、1_scanner_test.pp.c、1_scanner_test.tokens 文件，1_scanner_test.tokens 文件部分内容如下图:

7. 实验心得体会

通过本实验，我有如下收获：

（1）对词法分析器的工作原理和具体步骤有了深入理解。词法分析器输入源程序，输出属性字流，通过确定有限自动机实现。

（2）通过阅读 JFlex 用户手册，对 JFlex 自动生成词法分析器的方法有了一定了解。JFlex 能够根据用户编写的正则表达式与操作方法自动生成确定有限自动机。优点是节省时间、减少人力编写自动机的工作量、减少出错的可能，让用户能够专注于正则表达式的撰写。缺点是自动生成的代码可阅读性和可维护性较差。